
Prédiction du buzz

Mohamed Morchid

Laboratoire d'Informatique d'Avignon (UPRES 931)

339, chemin des Meinajaries

Agroparc – B.P. 1228

F-84911 Avignon cedex 9

mohamed.morchid@etd.univ-avignon.fr

RSUM. La vidéo représente de plus en plus le media le plus utilisé par les internautes et plus généralement par les consommateurs de nouvelles technologies. Ainsi nous allons traiter dans ce papier de la détection automatique non supervisée de vidéos qui pourront créer le buzz. Pour ce faire nos corpus sont constitués de la base de données Wikipédia 2008¹ et des dépêches de l'AFP². Pour extraire de ces corpus les concepts, nous utilisons LDA. Nous proposons un ensemble de méthodes de détection automatique de concepts au sein d'un document multimedia. Il sera montré en particulier les résultats obtenus par la méthode "intersection". Nous exposerons les différents indicateurs permettant de mesurer la "buzzabilité" d'un document. Nous montrerons l'intérêt de la prise en compte des concepts dans l'extraction du concepts dominants à travers des expérimentations de titrage automatique et d'extraction de tags de vidéos.

ABSTRACT. Except the video is increasingly the media most often used by Internet users and more generally by consumers of new technologies. Thus we will address in this paper the automatic unsupervised videos that will create the buzz. To do this our body consist of the Wikipedia database and news from AFP. Corpus to extract these concepts, we use LDA. We will propose a method for automatic detection of unsupervised concept in a multimedia document. We will expose a method for detection of concept "sensitive" can lead to a buzz. We will see the advantage of topics in the texttiting and the tags extraction.

MOTS-CLS : buzz, classification, LDA, concept, Hellinger, Kullback-Liebler, Cosinus

KEYWORDS: buzz, LDA, topic classification, thematic clustering, Hellinger, Kullback-Liebler

1. fr.wikipedia.org

2. www.afp.com

1. INTRODUCTION

La taille des informations collectées grâce au web est de plus en plus importante. Les utilisateurs se muent en contributeurs du web via les blogs, les réseaux sociaux, les forums et leurs avis sur des produits ou prestations. Ainsi les médias susceptibles d'être issus de la contribution des internautes sont de plus en plus variés. Auparavant seuls les documents textuels étaient partagés par les contributeurs du web, mais avec l'avènement des sites de partages photos (Flickr), textuel (Blogs, journaux, avis de consommateur, ...), vidéo (Youtube, Dailymotion, ...) et audio (radio en ligne), l'ensemble des médias sont investis. Pour ces raisons, le buzz peut être généré par du texte, du son ou, plus fréquemment, par les vidéos.

1.1. Définition

Une définition unique du buzz est complexe à déterminer. On peut considérer qu'un document réalisera le buzz s'il est consulté un grand nombre de fois dans un laps de temps court. Ainsi la composante temporelle prend une grande importance. Par exemple, un extrait de film pourra être visionné un grand nombre de fois mais dans un laps de temps long. P. Froissart [FRO 07] considère le buzz comme un phénomène sans lien direct et exclusif avec l'information, mais quelque chose de plus créatif, participatif et expressif.

1.2. Quelques remarques sur le buzz

Ainsi un buzz donne souvent lieu à des créations plus ou moins artistiques. On peut prendre comme exemple la réplique. Une vidéo ayant créé le buzz se voit susciter des répliques qui peuvent prendre différentes formes : la caricatures, le détournement, la copie revisitée, C'est pour ces raisons que l'on se doit de distinguer le buzz de la vidéo populaire due à son contenu. Comme nous l'avons vu précédemment, le buzz n'est pas uniquement issu de l'information (il peut l'être en partie comme des phénomènes d'actualité), mais issu essentiellement d'un mouvement créatif, et d'appartenance à un groupe comme le précise P. Froissart [FRO 07]. Nous avons alors deux catégories de vidéo :

→ Buzz, lié à un contenu créatif, expressif.

→ Populaire, lié au contenu même de la vidéo ¹

Lors de notre étude nous avons gardé à l'esprit que les vidéos pouvant potentiellement réaliser le buzz se distinguent par un contenu spécifique. La recherche d'éléments caractérisant la potentialité qu'une vidéo a de faire le buzz est soumise à la façon dont ont défini le phénomène.

1. lieu connu, célébrité, événement politique ou sportif d'envergure, monument...

Cette difficulté à donner une définition précise du buzz complexifie la méthode de détection du buzz. Une des tâches que nous avons à surmonter était de déterminer quels sont les indicateurs de buzz.

La suite du papier est organisée comme suit : la section 2 traite des travaux déjà réalisés dans la détection de concepts. L'approche que nous avons choisi sera exposée dans la section 3. Nous poursuivrons par la détermination du modèle du monde dans la section 4. Un lexique sera donné en section 5 puis nous verrons les différentes méthodes de calcul de la similarité entre un document et un *topic* dans la section 6. Les méthodes permettant l'extraction de l'élément caractéristique du document seront vues dans la section 7, puis nous exposerons dans la section 8 les indicateurs permettant de déterminer le potentiel de buzz d'un document. Dans la section 9 nous déterminerons la manière de noter la "buzzabilité" d'un document. La section 10 sera réservée aux expérimentations. Nous concluons dans la section 11 et parlerons des perspectives dans la section 12.

2. ETAT DE L'ART

Nous avons décomposé notre travail en deux parties distinctes : recherche des concepts les plus représentatifs d'un document, puis recherche du degré de sensibilité de cet ensemble de concepts.

2.1. *Décomposition en espace de concepts*

La recherche de concepts dans le multimédia est une problématique spécialement intéressante car elle nous permet de basculer d'un modèle vectoriel du document à un ensemble de concepts décrivant le document beaucoup plus abstrait et révélateur de la sensibilité du message véhiculé par le document. La génération d'un espace conceptuel à partir d'un corpus permet de considérer l'espace de projection non plus comme un espace de mots mais un espace de concepts.

Plusieurs méthodes de création d'espace de concept ont été mises en place. Ainsi [DEE 90] expose la méthode de d'indexation par LSA (Latent Semantic Analysis). Cette méthode permet de traiter les relations entre des mots d'un document pour en extraire des ensembles de mots appelés classes de mot. Pour se faire, il utilise une décomposition en composantes principales SVD (Singular-value decomposition). Cette décomposition permet la création d'un espace pour représenter les relations entre les données tout en ne tenant pas compte des relations les moins importantes. Dans [GEN 08] Liqiang Geng et al. ont comparé les performances de classification du modèle LDA comparativement au modèle AT pour déterminer la relation auteur-*topic*. Le modèle AT² est un modèle décrivant la relation entre l'auteur et le *topic* sans prendre

2. Author-Topic

en compte le contenu du message. Ils démontrent ainsi le net avantage de performance de LDA comparativement à la base-line qu'est le modèle AT. Les résultats montrent qu'en combinant AT et LDA on obtient des résultats inférieurs à LDA seul.

Des approches non probabiliste existe comme l'utilisation de relation statique entre mot comme les synonymes ou une hierarchie entre mots comme "IS_A" qui indique par exemple que **chat EST_UN animal** (IS_A{chat,animal}). Ainsi dans [HOT 03], ils comparent leur système de classification automatique à une classification manuel. Leur representation d'un vecteur de documents est une representation vectorielle dont chaque composante est le TF*IDF du mot. Ils utilisent également des methodes de remplacement du TF*IDF du terme par l'importance d'un concept issu de l'ontologie de WordNet [CHA 07] pour le document. Ils passent ainsi d'un vecteur composé de TF*IDF de mot à un vecteur de score de concept pour le document. La mesure de similarité utilisée est le cosinus entre les vecteurs representant les documents pour en determiner la proximité et ainsi des ensembles. Ils montrent alors l'apport des connaissances a posteriori dans la tache de création d'espace de concepts. D'autres utilisent également WordNet pour la catégorisation automatique de texte ([ROD 00]) en combinant pondération d'un terme et fréquence d'apparition dans les classes.

L'utilisation du dictionnaire de synonyme WordNet est très répandue dans la recherche des concepts et dans la désambiguïsation d'éléments. Ainsi, [LIN 06] utilise l'algorithme CDC³ pour déterminer les concepts contenus dans un document pour combler les différentes failles de WordNet. Pour chaque mot rencontré, on calcule un vecteur de contexte. Si un mot est rencontré dans un contexte, on lui attribue une valeur dans le vecteur du mot, correspondant à l'information mutuelle entre le mot et le contexte. Par exemple si le mot **lait** est rencontré après **c'est une vach à**, on déterminera alors une entrée pour le vecteur mot : lait. L'algorithme CBC est constitué de trois phases : (1) On calcul les 20 éléments les plus similaires à un mot w_i . (2) Le système reçoit en entrée la base de données des similarités déterminées dans la phase (1) et un ensemble d'éléments E à classifier. On détermine pour chaque élément s'il couvre bien le *topic*⁴. Pour cela on ne conserve que les éléments de E ayant une similarité avec le centroïde du *topic* dépassant une valeur seuil.(3) Dans cette dernière phase on assigne à chaque élément le *topic* pour lequel la similarité avec le centroïde est moindre. Des expérimentations ont montré que CBC obtenait des résultats meilleurs que d'autres algorithmes comme K-means, Buckshoot,L'algorithme CBC montre le potentiel de la recherche de concepts grâce au *classe comité*. JH Wang [WAN 10] utilise un processus en trois phases pour déterminer les concepts contenus dans une base d'articles : traitement préalable, extraction de mots puis enfin la détection de concepts. Cette base est issue d'articles anglais et chinois. Pour traiter les documents chinois, JH Wang utilise PAT-tree [CHI 99] qui est une structure en arbre utilisant les délimiteurs ', ' et ' ' pour formaliser le contenu d'une phrase sous forme d'un arbre. Cette approche est composée de trois phases :(1)extraction des articles le contenu sémantique en utilisant

3. Clustering By Committee

4. *topic* = concept

une stop liste et un décodeur de caractères pour le chinois.(2) On calcule la fréquence d'apparition de motif dans le document. Ce calcul de fréquence utilise les mots apparaissant à gauche et à droite du mot. Pour le chinois, ils utilisent PAT-tree qui donne une bonne représentation des différentes combinaisons de caractères possibles.(3)Le système utilise ensuite le $tf.idf$ pour déterminer la similitude entre mots et dégager un ensemble de classes. Les résultats ainsi trouvés sont bons au delà d'un certain seuil⁵. Cette approche demande néanmoins d'être expérimenté sur des ensembles de données plus volumineux (ici que 75,114 articles Chinois et 84,788 Anglais). Cette approche n'a également pas été évaluée sur la qualité des concepts trouvés hormis le nombre de concepts retirés ayant des mots en communs. Ces approches ont démontré leur performance et également certaines limites ou immaturité. Ainsi pour être utilisé sur des données plus volatiles comme les documents réalisant du buzz qui par définition n'ont pas de constitution sémantique forcément ordonnées. Notre approche sera alors d'utiliser le modèle LDA pour extraire à partir d'un corpus de documents, un ensemble de concepts. Cette approche a montré son efficacité sur des corpus de grande taille. De plus nous avons opté pour une approche non-supervisée de clustering.

2.2. Détermination des concepts les plus proches du document

Pour déterminer parmi tous les concepts issus de la LDA, lesquels sont les plus proches de notre document, nous devons déterminer quelle distance entre document et concept choisir. Bon nombre de distance ont été étudiées [ADH 56]. Dans [TAN 06], Tan et al. utilisent une représentation vectorielle du document. Ainsi, chaque document d est composé de N mots, chaque mot a alors un poids $w_i, i \in 0, \dots, N$ correspondant à sa fréquence tf multipliées par son idf . L' idf donne une mesure de rareté du mot au sein du corpus⁶ dans le document. Le calcul de similarité est réalisée en déterminant le cosinus entre deux documents donc deux vecteurs de fréquence de mots. D'autres utilisent la distance de Kullback-Liebler [KUL 51] pour déterminer une valeur de divergence entre documents ou la distance de Hellinger [SCH 11, SIM 10].

2.3. Extraction du concept dominant

Une fois les concepts les plus proches du documents trouvés, nous devons extraire un nouveau concept décrivant au mieux ce document. Plusieurs études se sont intéressées à l'extraction de mots clés. Ainsi dans [KEN 00] ils utilisent une approche statistique (EM) issue de travaux précédents de traduction français-anglais. Cette approche vise à maximiser $P(t_{an}|t_{fr})$. ils implémentent cette méthode pour déterminer quel titre "t" maximise $P(t|d)$ depuis une paire de titre/document issu d'un corpus

5. $seuil > 0.2$

6. $\log \left(\frac{N}{n_{w_i}} \right)$ avec N le nombre de documents composant le corpus et n_{w_i} le nombre de documents contenant le mot w_i

de 40 000 news. Ils améliorent la précision et le rappel et obtiennent de meilleurs résultats qu'une approche Bayésienne : précision 20% $\rightarrow$ 30%, rappel 50% $\rightarrow$ 40% . D'Avanzo et al. [D'A 04] expose le système LAKE ⁷. Ce système est basé sur une approche d'apprentissage supervisée. Ils se décompose en deux tâches : (i) Extraction d'un ensemble de phrases candidates au titrage du document, (ii) puis sélection des phrases les plus représentatives du document. Pour attribuer un score, ils utilisent la position du mot (unigramme) ou du mot de tête pour un ensemble de mots (verbes, noms,...) et le TF.IDF. Dans ce papier [DAN 10], l'équipe de R&D de EDF détermine le concept véhiculé par l'utilisateur lors d'un appel téléphonique (positif, négatif, opinion sur EDF,...). Ils utilisent le corpus Callsurf [BOZ 09, GAR 08] pour créer leur modèle pour l'ASR du LIMSI-CNRS. Ils déterminent ensuite le concept véhiculé par la technologie de TEMIS. Ils traitent également les différents problèmes de fluidité de langage propre au français (répétition, pauses,...). Ils gardent ensuite un ensemble de concepts propres à leurs tâches (durée, positif, négatif, attentes, contrat,...). Lors de l'évaluation de leur système comparativement aux résultats obtenus manuellement, ils ont des scores de précision et de rappel similaire dans presque tous les concepts. Certaines études utilisent une approche statistique de traduction pour générer le titre depuis un document [WIT 99, BAN 00]. Banko et al. [BAN 00] présentent dans cet article une méthode de titrage différente de celles vues en extraction. Cette méthode détermine la vraisemblance d'apparition d'un ensemble de mot E dans le titre. Ils déterminent les coefficients de chaque terme par l'algorithme de Viterbi. Lors de l'expérimentation, ils ont ajouté deux sources d'informations : POS (Part Of Speech) et Position (du mot dans le texte) . On remarque que POS n'apporte pas de réelle amélioration contrairement à l'information issue de la position du mot dans le document. Dans cette étude [KUM 05], on réalise le résumé automatique d'un document en utilisant les HITS [KLE 99] et le page rank de [BRI 98]. Leur contribution est l'apport d'un score de popularité d'une phrase (ils ne travaillent pas sur les paragraphes ni les mots, car moins structurer que les phrases, plus malleable pour constituer un résumé). La première tâche est de décomposer le document en noeuds (phrases) et en liens (similarité entre les phrases et les mots (synonymie) dépassant un certain seuil). Ainsi on peut déterminer la popularité d'une phrase en comptant le nombre de liens qu'elle possède avec les autres phrases. L'extraction de mots rencontre d'autres problèmes comme l'identification de séquence de mots. Certaines langues (Chinois ,...) ne possèdent pas de caractère permettant de distinguer séparément deux mots (comme le caractère blanc en français). Dans [CHE 02], ils utilisent des règles de morphologie, syntaxe, ... pour remédier à ce problème. Avec les règles morphologiques ils obtiennent une précision d'environ 92%. Ils obtiennent des scores de 78% avec les règles statistiques. [TOD 10] proposent une méthode de recommandation de tags à l'utilisateur. Ils utilisent un modèle issu d'un corpus de 20,000 tags et le web pour trouver un ensemble de concepts caractérisant au mieux la vidéo. Leur système est similaire au système de tags automatiques de vidéos de Youtube ⁸. [YAM 08] proposent le système Synvie. Ce système propose le même service que Youtube mais permet à l'utilisateur de

7. Learning Keyphrase Extraction Algorithm

8. www.youtube.com

commenter les vidéos. Ces annotations peuvent être faites sur l'ensemble de la vidéo mais contrairement à Youtube, ces commentaires peuvent être réalisés sur une partie (scène) de cette vidéo. Quand ces commentaires sont générés par un utilisateur, des tags sont automatiquement créés.

2.4. "Sensibilité" d'un concept

De nombreuses études menées ont utilisées SentiWordnet [BAC 10, SAG 10, DEN , DEN 08]. Cette base de donnée est composé de manière similaire à WordNet [CHA 07], un dictionnaire de concepts et non de mots. Ainsi chaque mot est affublé d'une estimation permettant d'indiquer si le mot a une connotation positive ou négative. Comme nous l'avons défini dans la section "Introduction", le buzz possède des caractéristiques autres que juste sémantique (temporelle, antagonisme des thèmes qui le compose, ...). Pour cette raison nous devons également tenir compte de la composante temporelle. [GEL 02] utilisent la composante temporelle lors de l'élaboration de leur espace de concepts en déplaçant une fenêtre temporelle sur les documents composant le corpus. Ainsi, ils obtiennent un espace de concepts qui évolue avec le temps. Nous avons décidé d'incorporer la composante temporelle quand l'espace de concepts est construit. Ceci car nous devons déterminer la sensibilité d'un document multimédia instantanément. De plus, la constitution d'un nouveau corpus pour chaque période de temps composant la fenêtre temporelle, peut se faire uniquement sur des corpus nécessitant peu de traitement. Dans notre cas, nous constituons notre espace de concepts à partir de plus de 3 millions de documents. Si nous voulions établir un nouveau corpus par fenêtre, il faudrait alors en générer à chaque fois, ce qui n'est pas possible pour l'application que l'on traite.

3. NOTRE APPROCHE

Dans ce papier, nous proposons une approche non-supervisée pour détecter quels sont les principaux concepts véhiculés au sein d'un document textuel ou audiovisuel en utilisant le modèle génératif LDA⁹. Nous extrayons ensuite des concepts les plus proches du document un ensemble de mots constituant le concept dominant du document. Sachant cette ensemble de mots, nous allons ensuite déterminer le degré de sensibilité de cette ensemble. Ainsi un article traitant simultanément de différents concepts de forte sensibilité (guerre, sexe, sport, politique ,...) ou ayant une forte divergence, seront alors susceptibles de générer du buzz. Pour ce faire nous disposons d'un ensemble d'indicateurs. Nous pourrions alors prédire automatiquement si un document textuel peut générer du buzz. Nous traiterons ensuite du cas de la vidéo qui est similaire à celui du texte. Nous allons récupérer le contenu audio sous la forme de texte grâce au système de reconnaissance de la parole SPEERAL¹⁰ du LIA¹¹. Le

9. Latent Dirichlet Allocation

10. SPEECH Recognition Avignon Laboratory

11. Laboratoire d'Informatique d'Avignon

texte ainsi extrait sera alors traité comme un document textuel. La création du modèle de classe et la projection du document dans cette espace est réalisé dans la **Partie I**. Dans le **Partie II** nous déterminons les indicateurs permettant d'attribuer une note de "buzzabilité" au document.




Figure 1. Notre approche en deux parties : **Partie I** correspond à l'extraction du concept dominant, la **Partie II** correspond à la notation de "buzzabilité" du document via les indicateurs.

Partie I

- Création du modèle du monde par une LDA sur le corpus issu de Wikipédia et des dépêches de l'AFP
- Extraction des concepts les plus proches du document
- Choix du concept dominant

Partie II

- Notation du concept dominant avec les indicateurs de dates et de "sensibilité".
- Recherche dans le flux RSS de grands médias souvent consultés, de l'importance des mots constituant le concept dominant du document.
- Notation des concepts proches du document avec l'indicateur d' "antagonisme".

Lors de notre étude, nous avons confronté toutes ces méthodes et évalué leurs efficacité selon les critères de précision, rappel et f-score pour la détection de concepts au sein d'un document. Nous verrons dans les sections qui suivent les méthodes choisies pour déterminer les concepts proches du document et les méthodes pour en extraire le concept dominant.

4. CONSTITUTION DES MODELES DU MONDE

Nous avons décidé de déterminer les concepts grâce à une modélisation du monde par une LDA. L'avantage de LDA comparativement à d'autres méthodes comme LSA, LSI, ... est de tirer aléatoirement la manière de choisir une loi de tirage de topic (Section 2.1). Celle-ci va nous permettre de dégager un ensemble de classes qui représenteront nos concepts. Dans cette section nous allons dans un premier temps exposer de manière intuitive ce qu'est LDA (4.1), puis nous détaillerons la composition des concepts (4.2). Nous détaillerons enfin l'outil utilisé pour l'élaboration des modèles (4.3)

4.1. Latent Dirichlet Allocation ou LDA

Lors de l'étude de LDA par [RIG 06], on a pu constater de son importance et de son apport comparativement aux autres modèles génératifs que son Latent Semantic Indexing (LSI) [DEE 90, Kub 01, MAR 04], Probabilistic Latent Semantic Indexing (PLSI) [HOF 99b] et Probabilistic Latent Semantic Analysis (PLSA) [HOF 99a]. Cette apport est essentiellement du au fait que LDA considère que le lien entre les thèmes et le document n'est plus une loi multinomiale dont les paramètres doivent être déterminés par la mise en place de l'algorithme EM¹² mais les occurrences de mots dans le document. LDA est alors un modèle probabiliste génératif qui considère un document comme un "**sac de mots**" [SAL 89]. Les occurrences de chaque mot sont liées par une variable latente déterminant la distribution des *topics* au sein d'un document. Ce modèle permet la catégorisation non supervisée de documents. [BLE 03] décrit LDA pour chaque document d_i constituant le corpus C :

- 1. On détermine la taille du document $\sim \text{Poisson}(\xi)$.
- 2. On tire la loi qui nous permettra de tirer le *topic* $\sim \text{Dir}(\alpha)$.
- 3. Pour chaque mot :
 - On choisit un *topic* $z_n \sim \text{Multinomial}(\theta)$.
 - On choisit un mot appartenant conditionnellement au *topic* : $P(w_n|z_n, \beta)$

Cette définition basique permet de constater que LDA (contrairement aux autres modèles génératifs) ne tire pas le *topic* selon une loi statique, mais dynamique . Cette partie dynamique est réalisée par le tirage selon une loi de dirichlles paramètre d'oc-

12. Expectation-Maximisation

currence de mot (β) et de distribution de thèmes au sein d'un document (α). Un inconvénient de LDA est qu'il peut engendrer des *topics* au contenu incohérent.

4.2. Constitution des corpus d'apprentissages

LDA nécessite un ensemble de données pour constituer le modèle. Cet ensemble de données (ou corpus) fut élaboré avec différentes sources d'informations. Nous avons choisi de prendre les documents issus de Wikipédia et de l'AFP à hauteur de 1 Go pour Wikipédia et de 4.5 Go pour les dépêches de l'AFP. Ceci constitue un peu plus de 3 millions de documents.

Corpus

Nous établissons ainsi deux modèles. Nous avons ainsi gardé les deux modèles les plus efficaces. Nous avons ainsi testé un ensemble de modèles avec un nombre différent de classes (de 1000 à 10,000), différent de mots (10,20,50 mots par classe et chunks par classe). Nous avons également testé des modèles issus de corpus lemmatisés avec différentes expressions régulières. Nous avons retenu une expression régulière qui conserve le nombre et tous les caractères de au moins deux lettres :

→ Wikipédia et AFP avec 5000 Concepts Lemmatisés

→ Titres des dépêches de l'AFP avec 10 000 Concepts Lemmatisés

Le choix des articles issus de Wikipédia et des dépêches de l'AFP fut guidé par la problématique que l'on traite, à savoir la détection de "buzzabilité" d'un document. Un buzz, comme nous l'avons défini dans la section (1) est un événement sans lien direct avec l'information. Ainsi, nous avons voulu modéliser deux aspects de cette incertitude : une définition précise d'un élément (Wikipédia) et l'élément disposé dans la plus grande partie des environnements où il serait susceptible d'évoluer (AFP). La jonction de ces deux représentations d'un élément nous permet alors de le disposer tant sémantiquement qu'environnementalement. Le choix du nombre de classes fut effectué de telle sorte que chaque concept ne soit pas spécifique ou trop général. Le dernier corpus fut lemmatisé. Ainsi on peut constater que les classes issues de LDA peuvent se merger plus facilement et que les mots redondants (issus d'un même nom, conjugaison,...) n'occupent pas une place inutile.

Le système pourra alors les réunir sous une seule classe et ainsi augmenter le nombre de classes pertinentes.

4.3. Outil utilisé

L'outil que nous avons utilisé pour la détermination des modèles est une implémentation de LDA en Java : Mallet. Cet outil a été réalisé par David Mimno [MCC 02]. Nous avons choisi cet outil car la détection de buzz est réalisée par un ensemble sé-

$topic_0$	$topic_1$	$topic_{0_{lemme}}$	$topic_{1_{lemme}}$	$topic_{0,1}$
déplacement déplacé déplaçais mouvement mouvance mouvoir transporter meut transport	transport avion déplacement transporter transporté	déplacement déplacer mouvement mouvance mouvoir transport transporter	transport avion déplacement transporter	déplacement déplacer mouvement mouvance mouvoir transport avion transporter

Tableau 1. Au départ nous avons deux topics distincts ayant une intersection commune faible. En lemmatisant les topics, on constate que leur intersection peut être étendue et ainsi permettre de merger (joindre) les deux topics. En rouge sont indiqués les mots issus du $topic_0$ dans le $topic_{0,1}$ mergé. En bleu sont indiqués les mots issus du $topic_1$ dans le $topic_{0,1}$ mergé. En vert sont indiquées les mots communs aux deux topics

manique propre au langage courant. Mallet, en plus de détecter les différents concepts dans un corpus de documents, permet également d'extraire un ensemble d'expressions (au moins deux mots) associées à un concept. Nous disposons ainsi d'une structure sémantiquement plus forte pour déceler un message transmis au sein d'un document. Nous avons utilisé cette expression (appelé phrase) pour extraire au sein d'un ensemble de concepts l'élément caractérisant le document.

5. LEXIQUE

5.1. Représentation d'un document

Nous considérons chaque document comme un "sac de mots". Ainsi, on peut représenter chaque document comme un vecteur dont chaque élément représentera la fréquence tf_{w_i} d'apparition du mot w_i dans le document multiplié par la rareté du mot dans le corpus (idf_{w_i}) [ZHA 10] :

$$tf_{w_i} = \frac{n_{w_i}}{\sum_{k=0}^N n_{w_k}}$$

Avec pour chaque mot w_i du document, n_{w_i} le nombre d'occurrence du mot dans le document et $\sum_{k=0}^N n_{w_k}$ le nombre totale de mots dans le document. L' idf d'un mot w_i vaut :

$$idf_{w_i} = \frac{|D|}{|\{d_j : w_i \in d_j\}|}$$

où :

$|D|$ représente la taille du corpus (nombre de documents inclus dans le corpus).

$|\{d_j : w_i \in d_j\}|$ représente le nombre de documents où le mot est apparu.

Nous avons décidé de lemmatiser les mots contenus dans le document. Un lemme est la forme canonique du mot. Pour un verbe : ce verbe à l'infinitif, pour les autres mots : le mot au masculin singulier. Par exemple si l'on prend le mot chat, il peut se décliner sous les formes de : chat, chats, chatte, chattes. Ainsi, en lemmatisant on ne garde que le nom : chat. Ici le gain est de quatre mots. La représentation du document dans l'espace des mots lemmatisés est alors un vecteur de tf_{w_i} .

5.2. Représentation d'un topic

La fiche d'identité d'un *topic* est constituée d'un identifiant et du nombre de mots qu'il contient. Au sein de chaque *topic*, se trouve un ensemble de mots et de chunks avec leur probabilité d'apparition dans le *topic*. Chaque chunk est constitué d'une suite de mots¹³ concurrents *Figure2*.




Figure 2. Représentation d'un topic avec Mallet

¹³. au moins deux

5.3. *chunk*

5.3.1. *Quest donc un "chunk" ?*

Mallet [MCC 02] connecte des séquences de mots contigus assignés à un même concept et réalisant les mêmes choses. Par exemple, si la séquence de mots est "une chatte[1] vivait dans une maison[2] en brique[2] avec son chaton[1] et un chat[1]" (le numéro du *topic* entre crochet), nous extrairons de la phrase "*maison brique*" pour le **topic 35** et "*chaton chat*" pour le **topic 1**.

5.3.2. *Score du mot w_i au sein des chunks du topic t_k*

Nous avons également introduit un score (r_{ch}) pour chaque mot en fonction de sa rareté au sein de chunks du *topic*. Ainsi un mot possède un idf_{w_i} représentant sa rareté au sein du corpus et un r_{ch} représentant sa rareté au sein d'un *topic*. L' r_{ch} du mot au sein d'un *topic* est déterminé en tenant compte du maximum des probabilités d'apparition de l'ensemble des chunks contenant le mot au sein du *topic* et du $\log$ de la fréquence d'apparition du mot au sein des chunks. Nous avons alors :

$$r_{ch}(w_i, t_k) = -\max \log \left(\frac{n_p(t_k)}{n_{p_j, w_i \subset p_j}} \right)$$

$\max$ est la probabilité maximum atteint par les chunks ch_j du *topic* t_k contenant le mot w_i , $n_{ch_j, w_i \subset ch_j}$ le nombre de chunks du *topic* t_k contenant le mot w_i et $n_{ch}(t_k)$ le nombre de chunks contenu dans t_k .

6. SIMILARITE ENTRE UN DOCUMENT ET UN CONCEPT

Après la constitution de l'ensemble des concepts représentant " le monde ", nous devons projeter le document dans ce nouvel espace et en extraire les concepts les plus proches du document, et donc les plus représentatifs de l'idée véhiculée par ce document. Nous avons mis en place différentes méthodes de calcul de similarité. Dans cette section (6.1) nous allons les détailler en commençant par la méthode par probabilité conditionnelle. Puis nous verrons la méthode de calcul de similarité par le cosinus dans la section suivante(6.2). Dans la partie (6.3) nous verrons en quoi la distance de Hellinger nous permet d'avoir des résultats proches de ceux issus de la méthode du "cosinus". Enfin, nous verrons dans la section (6.4) la méthode de Kullback-Liebler.

6.1. *Similarité par produit scalaire*

Lors de l'élaboration de cette méthode, nous avons souhaité prendre en compte l'importance du mot dans le document ($P(w_i|t_i)$ ou tf), la rareté du mot dans le corpus (idf_{w_i}), l'importance du mot pour chaque *topic* t_i ($P(w_i|t_i)$). Nous avons également voulu prendre en compte le mot dans son contexte. Pour ce faire nous avons déterminé l'importance de tous les bigrammes apparaissant dans le document ($P(b_i|d)$)

) et sa représentation dans le *topic* ($P(p_i|t_i)$). Sachant qu'un bigramme est composé de deux mots w_1 et w_2 , nous obtenons le score de similarité entre un document et un *topic*. On réalise alors le produit scalaire entre le vecteur document de composante les $tf.idf$ de chaque mot, et le vecteur *topic* composé des $P(w_i|t_i)$:

$$SimCond(d, t_i) = SimCond(w_i \in d, t_i) + SimCond(b_i \in d, t_i) \quad (1)$$

avec :

$SimCond(w_i \in d, t_i)$ représente la similarité conditionnel entre les mots w_i contenus dans le document d et le *topic* t_i .

$SimCond(b_i \in d, t_i)$ représente la similarité conditionnel entre les bigrammes b_i contenus dans le document d et le *topic* t_i .

Dans cette formulation nous avons choisi " booster " un *topic* ayant des chunks contenant les bigrammes. Ainsi, nous tenons compte de la popularité du mot au sein des différentes chunks constituant le *topic*. Nous ajoutons au score obtenu par le mot, la somme des scores relatifs de chaque mot constituant le bigramme. Nous pondérons la partie concernant les mots pris seuls par le maximum des idf atteint par chacun des deux mots du bigramme. Nous avons alors le score pour chaque mot :

$$SimCond(w_i \in d, t_i) = \sum_{w_i \in d} tf_{w_i} . idf_{w_i} . P(w_i|t_i) \quad (2)$$

et pour chaque bigramme :

$$SimCond(b_i \in d, t_i) = \sum_{b_i \in d} ((r_{ch}(w_1, t_i) + r_{ch}(w_2, t_i)) . P(b_i|d) + (P(w_1|t_i) . P(w_1|d) + P(w_2|t_i) . P(w_2|d)) . max\{idf_{b_i}\}) \quad (3)$$

b_i représente les bigrammes du document composés de deux mots (w_1, w_2) , $max\{idf_{b_i}\}$ représente l' idf maximum atteint par les deux mots composants le bigramme ($max\{idf_{w_1}, idf_{w_2} : w_1 \subset b_i, w_2 \subset b_i\}$).

6.2. Similarité par cosinus

Cette méthode utilisée du "cosinus" entre un vecteur document d de coordonnées les $tf_{w_i} . idf_{w_i}$ des mots le constituant et un vecteur de composantes le $P(w_i|t_i) . idf_{w_i}$ pour représenter le *topic* t_i [SAL 88, BER 95] est la suivante :

$$SimCosinus(d, t_i) = \frac{\vec{d} . \vec{t_i}}{||\vec{d}|| . ||\vec{t_i}||} \quad (4)$$

avec :

$$\vec{d} \cdot \vec{t}_i = \sum_{w_i \in d} tf_{w_i} \cdot idf_{w_i} \cdot P(w_i | t_i) \quad (5)$$

et :

$$\|\vec{d}\| \cdot \|\vec{t}_i\| = \sqrt{\sum_{w_i \in d} (tf_{w_i} \cdot idf_{w_i})^2} \cdot \sqrt{\sum_{w_i \in t_i} (P(w_i | t_i))^2} \quad (6)$$

Le calcul du cosinus détermine l'angle entre le document et le *topic*. Cette mesure permet de ne pas privilégier un *topic* de grande taille comparativement à un *topic* plus petit mais potentiellement plus pertinent. Le produit scalaire du numérateur est pondéré par le produit des modules des vecteurs document et *topic*. Ainsi nous obtenons un score de similarité entre le document transmis en requête et un *topic*.

6.3. Similarité par cosinus avec r_{ch}

Le cosinus doit être calculé entre deux vecteurs les plus représentatifs du document et du *topic* pour en extraire leur score de similarité. Nous avons alors décidé d'inclure le score du mot w_i au sein des chunks constituant le *topic* t_k . Ceci permet de tenir compte pour chaque mot w_i du document de sa popularité au sein du *topic* ($P(w_i | t_k)$) et de son degré de cooccurrence avec les autres mots du *topic* ($r_{ch}(w_i, t_k)$) :

$$SimCosinus_{ph}(d, t_i) = \frac{\sum_{w_i \in d} tf_{w_i} \cdot idf_{w_i} \cdot P(w_i | t_k) \cdot r_{ch}(w_i, t_k)}{\sqrt{\sum_{w_i \in d} (tf_{w_i} \cdot idf_{w_i})^2} \cdot \sqrt{\sum_{w_i \in t_k} (P(w_i | t_k) \cdot r_{ch}(w_i, t_k))^2}}$$

6.4. Similarité par la distance d'Hellinger

Cette distance est utilisée pour quantifier la distance entre deux distributions de probabilités. Pour cela, nous devons disposer de deux distributions continues. Nous pouvons calculer la distance entre le document et chaque *topic* par :

$$\begin{aligned} SimHellinger(d, t_i) = H^2(d, t_i) &= \frac{1}{2} \int_{w_i \in d} \left(\sqrt{P(w_i | d)} - \sqrt{P(w_i | t_i)} \right)^2 dw_i \\ &= \frac{1}{2} \int_{w_i \in d} \left(\sqrt{P(w_i | d)}^2 - 2 \cdot \sqrt{P(w_i | d) \cdot P(w_i | t_i)} + \sqrt{P(w_i | t_i)}^2 \right) dw_i \end{aligned} \quad (7)$$

et puisque :

$$\begin{aligned} \int_{w_i \in d} (P(w_i|d)) dw_i &= \int_{w_i \in d} (P(w_i|t_i)) dw_i \\ &= 1 \end{aligned} \quad (8)$$

On a donc :

$$\frac{1}{2} \int_{w_i \in d} (P(w_i|d)) dw_i + \frac{1}{2} \int_{w_i \in d} (P(w_i|t_i)) dw_i = 1 \quad (9)$$

Le score de similarité de Hellinger entre le document et le *topic* vaut alors :

$$SimHellinger(d, t_i) = 1 - \int_{w_i \in d} \left(\sqrt{P(w_i|d) \cdot P(w_i|t_i)} \right) dw_i \quad (10)$$

Nous approximations la distance à l'aide du coefficient de Bhattacharyya [CHO 03] auquel on ajoute l'*idf* du mot et le score du mot au sein des chunks du *topic* :

$$SimHellinger(d, t_i) = 1 - \frac{idf_{w_i}}{r_{ch}(w_i, t_i)} BC(d, t_i) \quad (11)$$

avec :

$$BC(d, t_i) = \sum_{w_i \in d} \sqrt{P(w_i|d) \cdot P(w_i|t_i)} \quad (12)$$

En inversant l'ordre des *topics* trouvés (retrait du 1−, car $0 < SimHellinger(d, t_i) < 1$), on obtient le score de chaque mot du document :

$$ScoreMotHellinger(w_i, t_j) = \sqrt{P(w_i|d) \cdot P(w_i|t_j)} \cdot \frac{idf_{w_i}}{r_{ch}(w_i, t_j)} \quad (13)$$

on obtient donc pour l'ensemble des mots constituant le document :

$$SimHellinger(d, t_j) = \sum_{w_i \in d} \sqrt{P(w_i|d) \cdot P(w_i|t_j)} \cdot \frac{idf_{w_i}}{r_{ch}(w_i, t_j)} \quad (14)$$

6.5. Similarité par la méthode de Kullback-Liebler

La méthode de Kullback-Liebler permet de mesurer la divergence entre deux distributions de probabilités. La mesure de la similarité (ou divergence) de KL entre deux distributions de probabilités discrètes p_i et p_j est donné par :

$$SimKL(p_i, p_j) = \sum_k p_i(k) \log \frac{p_i(k)}{p_j(k)} \quad (15)$$

donc en ajoutant le symétrique et en prenant la moyenne on obtient :

$$SimKL(p_i, p_j) = \frac{1}{2} \left(\sum_k p_i(k) \log \frac{p_i(k)}{p_j(k)} + \sum_k p_j(k) \log \frac{p_j(k)}{p_i(k)} \right) \quad (16)$$

La similitude entre le document d et le topic t_i est la somme de leur similitude pour les mots et pour les bigrammes :

$$SimKL(p_i, p_j) = \frac{1}{2} (SimMotKL(d, t_i) + SimBiKL(d, t_i)) \quad (17)$$

Plus cette distance est petite plus le document d est proche du topic t_i . On peut interpréter la probabilité que le mot apparaisse dans le document comme le tf_{w_i} du mot w_i dans le document d . Nous avons également tenu compte des bigrammes apparus dans le texte et apparaissant dans les chunks du topic .

$$SimMotKL(d, t_i) = \frac{1}{2} \left(\sum_{w_k \in d} tf_{w_k} \log \frac{tf_{w_k}}{P(w_i|t_i)} + \sum_{w_k \in t_i} P(w_i|t_i) \log \frac{P(w_i|t_i)}{tf_{w_k}} \right) \quad (18)$$

et pour les bigrammes contenus dans le document d :

$$SimBiKL(d, t_i) = \frac{1}{2} \left(\sum_{b_k \in d} P(b_k|d) \log \frac{P(b_k|d)}{r_{ch}(w_1, w_2 \in b_k, t_i)} + \sum_{ch_k \in t_j} P(ch_k|t_j) \log \frac{P(ch_k|t_j)}{P(b_k \in ch|t_j)} \right) \quad (19)$$

où :

b_k est le k^{ieme} bigramme contenu dans le document.

ch_k est la k^{ieme} chunk contenu dans le topic.

$P(b_k \in ch|t_j)$ la probabilité d'un chunk ch du topic t_j qui contiendrait les deux mots du bigramme b_k .

7. METHODE D'EXTRACTION DU CONCEPT DOMINANT

Une fois les concepts représentatifs du document extrait, il nous faut à présent déterminer quel est l'ensemble permettant de décrire au mieux le document. Nous avons traité plusieurs méthodes d'extraction. Ici seront développées ces méthodes. Nous commencerons par le maximum atteint par le produit des scores pour chaque mot dans les *topics* (7.1). Puis nous verrons le choix des mots constituant l'élément caractéristique par la recherche des mots maximisant la valeur d'intersection entre les *topics* (7.2) et par la méthode d'union de concepts proches du document dans la section (7.3).

7.1. Méthode par score maximum

Pour chaque *topic*, Nous avons déterminé un score d'extraction noté ($score_{ext}$) pour chaque mot constituant chaque concept nous avons alors :

$$score_{ext}(w_i) = \max\{P(w_i|t_j).r_{ch}(w_i).Sim(d, t_j)\}$$

où $P(w_i|t_j)$ représente la probabilité d'apparition du mot w_i dans le *topic* t_j , $Sim(d, t_j)$ représente l'indicateur de similarité entre le *topic* t_i et le document d ¹⁴, N est le nombre de *topics* contenus dans le modèle, C représente l'ensemble des *topics* trouvés. Ainsi, pour chaque mot constituant le document, on détermine un score d'extraction qui est la valeur maximale atteinte par ce mot au sein des *topics*.

7.2. Méthode par composition des concepts proche du document

Nous avons un ensemble de concepts proches du document. Nous allons extraire de cette ensemble un sous-concept composé de mots des concepts proches. Pour se faire, nous allons réaliser des opérations élémentaire sur l'ensemble de concepts proches.

Méthode par intersection des concepts

Nous allons présenter ici le calcul de l'intersection entre les *topics*. Pour chaque mot constituant le document, on cherche la valeur d'intersection entre les mots composant le document et l'ensemble des *topics*. On réalise ensuite la moyenne harmonique entre les deux intersections¹⁵ :

$$score_{ext}(w_i) = \frac{2 * score_{Mot_{ext}}(w_i) * score_{Chunk_{ext}}(w_i)}{score_{Mot_{ext}}(w_i) + score_{Chunk_{ext}}(w_i)}$$

14. cosinus, KL, Hellinger,...

15. mots et chunks

Ainsi chaque mot et chunk rencontré dans le document déterminera un score d'extraction :

$$scoreMot_{ext}(w_i) = \sum_{t_j \in C} Sim(d, t_j) \cdot P(w_i | t_j)$$

Le score d'extraction pour un chunk est donné par :

$$scoreChunk_{ext}(w_i) = \sum_{t_j \in C} Sim(d, t_j) \cdot r_{ch}(w_i, t_j)$$

où C représente l'ensemble des *topics* trouvés, $P(w_i | t_j)$ représente la probabilité d'apparition du mot w_i sachant le *topic* t_j avec : $w_k \in t_j$, $Sim(d, t_j)$ représente l'indicateur de similarité entre le *topic* t_i et le document d .

Méthode par union des concepts

Cette méthode considère que le concept dominant est constitué des n mots les plus pertinents issus de l'union des m *topics* (t_j avec $j \in 0, \dots, m$) les proches du document. Cette ensemble est noté U_t . Pour déterminer cet ensemble, nous avons constitué un nouvel ensemble comportant les mots issus des *topics* proches avec comme score leur probabilité d'apparition dans le *topic* $P(w_i | t_j)$ multiplié par le score du *topic* pour le document $Sim(d, t_j)$ multiplier par le score du mot dans les chunks du *topic* $r_{ch}(w_i)$. Ce score de similarité entre document et *topic* est réalisé par l'une des méthodes de calcul de similarité entre document et espace de *topic* vu dans la section 6. Si un même mot apparaît dans plusieurs classes, on additionne ces scores :

$$score_{ext}(w_i) = \sum_{t_j \in U_t} P(w_i | t_j) \cdot Sim(d, t_j) \cdot r_{ch}(w_i)$$

Une fois l'ensemble de mots scores, on extrait de cet ensemble les n mots ayant le score le plus élevé.

8. CHOIX DES INDICATEURS DE "BUZZABILITE"

Lorsque le concept dominant est trouvé, nous devons à présent mesurer la "buzzabilité" de cet ensemble de mots. Pour ce faire, nous partageons cette mesure en deux étapes : statique et dynamique .

Indicateurs de "buzzabilité" statiques dans le temps

Ces indicateurs se décomposent en date d'apparition des mots qui le compose, de la sensibilité des mots composant le concept dominant du document et de l'antagonisme entre les *topics* proches du document. Ces indicateurs sont déterminés à priori et sont donc sans relation avec le flux d'information au temps t de l'estimation de "buzzabilité" d'un document.

Indicateur de "buzzabilité" dynamique dans le temps

Cette seconde étape est réalisée lors de la recherche de la "buzzabilité" d'un document. Elle consiste à déterminer l'impact des mots le composant dans l'actualité du web via les flux RSS. Cette étape est réalisée au moment de la détermination de la "buzzabilité" d'un document.

Nous allons détailler dans la section (8.1) l'indicateur de dates. Nous verrons ensuite comment nous avons déterminé l'indicateur de sensibilité grâce à au "twites" de Twitter ¹⁶ du concept dans la section (8.2). Enfin nous exposerons la manière de déterminer l'indicateur d'antagonisme (8.3) et le rôle des flux RSS dans le calcul de la "buzzabilité" d'un document dans la section (8.4).

8.1. Indicateur de temps

Nous disposons d'un corpus composé de dépêches de l'AFP ¹⁷. Ceux-ci sont datés. Nous avons alors un ensemble d'articles que l'on considère comme un ensemble de mots en relation avec une date. *Figure3*.

Nous obtenons alors pour chaque mot une liste de dates où il apparaît entre le premier mai 1994 et le premier juillet 2006. Nous pouvons déterminer un modèle de gaussiennes pour chaque mot en calculant la variance et la moyenne sur cette période des apparitions du mot. Ainsi notre indicateur sur la variabilité du mot dans le temps est représenté par la vraisemblance du mot sachant le modèle :

$$temps(p_{w_i}) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(p_{w_i}-\mu)^2}{2\sigma^2}}$$

Où p_{w_i} est la probabilité d'apparition du mot dans le document requête (fréquence du mot). On fait l'hypothèse que le comportement du mot dans le document peut se rapporter à celui du même mot dans le corpus AFP durant une semaine.

8.2. Indicateur de sensibilité

Nous avons utilisé le lexique de sensibilité issu des twites [PAR 10]. Ce lexique contient **976 mots** et est issu de ANEW (Affective Norms of English Words). ANEW est une liste de mots anglais élaborée par [BRA 99]. On compte pour chaque mot le nombre de fois où il apparaît près d'un émoticône positif ':' ou négatif ':('. Ainsi on obtient la valence du mot dans les twites. Cette valence est calculée en tenant compte de la probabilité que le mot soit rencontré dans un contexte positif $P(M^+|w_i)$:

$$valence(w_i) = 8.P(M^+|w_i) + 1$$

Ils obtiennent alors trois zones de mots : positive, neutre et négative : Nous voyons que

16. www.twitter.com

17. > de 3 millions de dépêches




Figure 3. Représentation d'une dépêche de l'AFP avec les deux représentations de la date et le texte considérés comme un "sac de mots". La date : 20020901 = 01/09/2002

la valeur de valence oscille entre 1¹⁸ et 9¹⁹. Pour déterminer de la sensibilité d'un mot w_i , nous ne distinguons pas le côté positif ou négatif du mot, mais son impact sur les utilisateurs de Tweeter. Ainsi un mot ayant été rencontré dans un contexte positif ou négatif majoritairement sera considéré comme "sensible". Ainsi nous avons centré la valeur de la valence pour quelle soit comprise entre 0 et 1 pour un mot sensible :

$$sensi(w_i) = 2 \cdot |P(M^+|w_i) - \frac{1}{2}|$$

et

$$P(M^+|w_i) = \frac{valence(w_i) - 1}{8}$$

Cette valeur sera proche de 1 si le mot a une valence proche de 8 ou 1 et nous indiquer alors si ce mot a été rencontré dans un extrême (positif ou négatif).

18. pour un mot majoritairement rencontré dans un contexte négatif

19. pour un mot majoritairement rencontré dans un contexte positif

Mots	$valence(w_i)$	Négatif	Positif	$sensi(w_i)$
Mots positifs				
félicitations	8,19	11	97	0,7975
bienvenue	8,18	46	401	0,795
joyeux	8,12	18	146	0,78
héhé	7,74	40	213	0,685
plaisir	7,62	116	557	0,655
merci	7,58	1092	5047	0,645
bonsoir	7,56	40	182	0,64
Mots neutres				
fsais	5,01	1126	1132	0,0025
sinon	5,01	460	462	0,0025
chérie	5	74	74	0
plage	5	65	65	0
puis	4,99	361	359	0,0025
savoir	4,97	219	216	0,0075
Mots négatifs				
craint	1,62	120	10	0,845
déprime	1,58	128	10	0,855
pleut	1,58	244	19	0,855
dégoutée	1,47	128	8	0,8825
dégouté	1,41	110	6	0,8975
décue	1,4	171	9	0,9
snif	1,24	317	10	0,94

Figure 4. Extrait des valeurs de valence pour chaque mots composant ASNEW. En bleu la valeur de notre indicateur de "sensibilité" compris entre 0 et 1.

8.3. Indicateur d'antagonisme

Nous avons remarqué que les documents réalisant le buzz sont généralement composé de thèmes antagonistes. Ces thèmes ne sont pas rencontrés fréquemment ensemble. Un document composé de concept habituellement incompatible ne produiront pas forcément du buzz. C'est pour cette raison que l'on a considéré l'antagonisme entre *topics* comme un indicateur et non un élément déterminant. Nous avons déterminé pour chaque couple de *topics* (t_i, t_j) avec $i \neq j$ la divergence de KL comme distance entre les *topics*. Nous avons ainsi formé un graphe non-orienté *Figure 5* ayant comme valeur pour chaque arc entre *topics* la divergence de KL normalisée. Si deux *topics* ont moins de 5% de mots en commun, on considère qu'il n'y a pas d'arc entre ces deux *topic*. Nous avons ensuite voulu déterminer la distance entre les *topics*. Nous avons le choix de calculer directement la divergence de KL entre deux *topics*. Cette distance aurait été la plupart des cas nulle car la majorité des *topics* ne partagent pas de mots. Nous avons alors décidé de considérer que les *topics* n'ont pas de lien direct forcément, mais




Figure 5. Representation d'un graphe entre 4 topics. Si nous devons, par exemple déterminer la valeur de divergence entre les topics 4 et 2, le chemin le plus court passe par les topics $4 \rightarrow 1 \rightarrow 3 \rightarrow 2$. On obtient alors une distance pas à pas de $0.024 + 0.112 + 0.157 = 0,293$ au lieu de la distance direct entre les topics 4 et 2 qui vaut 0,551

on toujours un lien indirect. Par exemple les topics "Politique" et "Sport". Ils n'ont pas de lien direct mais le topic "Politique" et le topic "Laporte" oui. De même le topic "Laporte" et le topic "Sport". Ainsi un lien indirect lie le topic "Politique" et le topic "Sport". Pour déterminer ce lien indirect, nous avons choisi de calculer le plus court chemin séparant les topics. Cette valeur sera déterminée par la distance de Dijkstra [DIJ 71] normalisée par le nombre d'arcs pour préserver un indicateur compris entre 0 et 1. Nous obtenons ainsi un indicateur d'antagonisme entre les topics :

$$anta(d) = \frac{1}{|E|} \sum_{t_i \in E} \sum_{t_j \in E, t_j \neq t_i} dist(t_i, t_j)$$

Avec E l'ensemble des topics proche du document et $dist(t_i, t_j)$ le plus courts chemin pour aller du sommet t_i à t_j . $|E|$ représente le nombre de concepts proches.

8.4. Indicateur de popularité

Cette indicateur permet de connaître l'affluence d'un mots issu du concept dominant au sein des principaux flux de media. Ainsi, nous récupérons les flux RSS de quatre grands quotidiens nationaux :

→ Le Monde²⁰

20. www.lemonde.fr

→ Liberation²¹

→ Le Figaro²²

→ L'Equipe²³

Nous déterminons alors avant le lancement du système, la "popularité" de chaque mot w_i de l'espace sémantique au sein des flux RSS :

$$popu(w_i) = \frac{\sum_{w_i \in rss} n(w_i)}{\max(popu(w))}$$

Où d représente une page contenue dans les flux RSS et $\max(popu(w))$ est le nombre maximum atteint par un mot dans le flux RSS. Ainsi nous obtenons un classement des mots rencontrés dans les flux RSS du plus "populaire" ($popu(w_i) = 1$) au moins populaire ($popu(w_i) \approx 0$).

9. NOTE DE "BUZZABILITE"

Nous venons de voir comment, à partir d'un document, extraire le concept dominant décrivant au mieux les différents concepts contenus dans ce document. Puis nous avons défini un ensemble d'indicateurs permettant de mesurer la sensibilité du document à partir du concept dominant. La tâche suivante consiste à déterminer les coefficients $\alpha, \beta, \gamma, \delta$ de l'équation de la note de "buzzabilité" $n_{buzz}(d)$ d'un document d :

$$n_{buzz}(d) = \frac{1}{N} \sum_{i=0}^N (\alpha.anta(d) + \beta.temps(w_i) + \gamma.sensi(w_i) + \delta.popu(w_i))$$

Avec N le nombre de mots contenu dans le concept dominant. Nous utilisons un réseau de neurones [DRE 02, NAD 93]. Nous utiliserons comme exemples en entrée du système les valeurs des indicateurs pour un ensemble de 156000 tweets, et comme classe attendu le nombre de retweet de chaque tweet. Ainsi nous avons pour chaque tweet un ensemble de 4 valeurs correspondant à la valeurs de chacun des indicateurs et une classe coresspondant au nombre de retweet. Ceci nous permet d'associer à chaque combinaison d'indicateurs une note objective liée au nombre de retweet du texte analysé.

Lors de la rédaction de ce rapport, le calcul des indicateurs pour un ensemble de 15,000 tweets était en cours. Nous obtiendrons donc un fichier contenant pour chaque tweet la valeur de chacun des 4 indicateurs suivie du nombre de retweet.

21. www.liberation.fr

22. www.lefigaro.fr

23. www.lequipe.fr




Figure 6. Représente un perceptron multi-couches avec en entrées les indicateurs ($i_1, \dots, i_4$), une couche cachés composé de deux neurones (4 entrées + 1 sorties divisé par 2 = 2 qui sont n_0 et n_1) et une sortie S

10. EXPERIMENTATIONS

Nous avons expérimenté chaque phase du calcul de "buzzabilité" d'un document. Dans la section (10.1) nous expérimenterons la recherche de concept dominant au sein d'un document. La première expérimentation consiste à évaluer la combinaison de nos méthodes (intersection et union) avec la base-line des meilleurs TF*IDF sur les mots. Ceci est réalisé sur des *news* pour déterminer les mots contenus dans le titre. La seconde expérimentation consiste à extraire les tags d'une vidéo avec nos méthodes et le TF*IDF sur la transcription de vidéos issu de youtube (sélection(10.2)). Ainsi, nous évaluons nos méthodes sur les tâches de découverte de mots dans un titre et de prédiction de tags dans des transcription de vidéos. Nous comparons les F-score de titres obtenus par *tf.idf* complétés d'éléments issus de l'"intersection" comparative au titre original d'articles issus de Amaryllis. Ensuite nous expérimenterons dans la section (10.3) la méthode de calcul de "buzzabilité". Nous soumettrons à notre système des documents, puis nous comparerons la note de "buzzabilité" obtenue par le système au degré de buzz mesuré par Wikio.

10.1. Prédiction de mots contenus dans un titre

Nous évaluons dans cette section les méthodes vues précédemment (Extraction des concepts proches du document, extraction de concept dominant) en utilisant 20461 articles issus d'"Amaryllis". Ces articles sont composés d'un titre. Nous avons alors

mesuré la qualité du titre trouvé comparativement au titre initial composé de mots issus de l'intersection et du $tf.idf$. Chaque ensemble de mots trouvé est alors composé de $n\%$ ²⁴ mots de l'intersection et de $(1 - n)\%$ de mots issus d'un $tf.idf$ sur le texte. Nous calculons la précision, le rappel et le f-score pour chaque ensemble de mots ainsi élaborer (Figure 7).




Figure 7. Courbe représentant l'évolution du F_{score} en fonction de la proportion de mots issus du $tf.idf$ et de la proportion de mots issus de l'intersection des concepts.

10.2. Prédiction de tags pour une vidéo

Nous avons récupéré pour cette expérimentation un ensemble de 100 vidéos issu de youtube (Voir Figure 8). Ces vidéos ont été récupérées après l'envoi d'une requête "journal actualité". Chaque vidéos ainsi postée sur le célèbre site de partage est accompagné d'un ensemble de tags. L'objectif de cette expérimentation est de prédire les tags à partir du texte issu de la retranscription de l'ASR ²⁵ SPEERAL ²⁶ du LIA ²⁷. SPEERAL utilise des HMM contextuels et des modèles de langage trigrammes, avec un vocabulaire d'environ 65000 mots. Le système fonctionne en deux passes, la première fournissant les transcriptions intermédiaires qui sont nécessaires à une adaptation au locuteur des modèles acoustiques. Nous obtenons ainsi pour chaque vidéo, un texte et un ensemble de mots clés représentant les tags de la vidéo. Nous comparons ensuite les tags ainsi récupérés à ceux issus de nos méthodes d'extraction

24. $n \in \{0, 25, 50, 75, 100\}$

25. Automatic Speech Recognition

26. SPEECH Recognition Avignon Laboratory

27. Laboratoire d'Informatique d'Avignon

(intersection et union). Nous comparons ces résultats à ceux obtenus par un TF.IDF sur la retranscription (baseline) en utilisant la précision, le rappel et le f-score (*Figure 9*). Les résultats de l'extraction des tags pour chacune des méthodes est décrite dans le *Tableau 2*.

Difficultés

La première difficulté est de projeter le document dans l'espace sémantique. Cet espace est obtenu par une LDA sur un corpus de texte. Ces concepts sont caractérisés par un ensemble de mots et d'expressions (appelé chunks) et leurs poids dans le concepts (classe). Ces chunks ont une grande importance dans la tâche d'extraction de tags : Contrairement aux mots, les tags sont souvent choisis pour attirer un maximum de visiteurs.

La seconde difficulté est l'extraction de mots clés. Les classes représentent principalement des thèmes trop étendus pour correspondre individuellement au concept dominant d'un document. Le problème est la projection du document dans l'espace des classes. Nous proposons une méthode qui combine l'extraction classique de mots-clés par TF-IDF et l'estimation d'une pseudo-classe est supposée centrée sur le concept principal. Cette pseudo-classe est obtenue de manière dynamique. Elle est estimée par intersection ou union des classes statiques.

Le troisième problème est due au passage par l'ASR. Nous choisissons 100 vidéos de YouTube avec la requête : actualité journal. La sortie de l'ASR ont un taux d'erreur d'environ 30 % pour les vidéos de news. Mais dans YouTube, toutes les vidéos ont été enregistrées avec une qualité faible et un niveau de langage faible par rapport à ceux issus de journaux télévisé. C'est pourquoi la sortie de SPEERAL donne quelques erreurs et certains mots vides due au langage parlé comme : euh,

Méthode		Precision	Rappel	F-Score
Inter	Avec chunks	0.05784	0.05784	0.05784
	Sans chunks	0.05559	0.05559	0.05559
Union	Avec chunks	0.01306	0.01306	0.01306
	Sans chunks	0.02465	0.02465	0.02465
TF-IDF		0.04789	0.04789	0.04789

Tableau 2. *Precision, Rappel et F-score pour l'intersection, l'union et le TF-IDF dans la tâche d'extraction de tags de vidéos issues de youtube.*

Nous constatons ainsi que les résultats les plus probants sont ceux de l'intersection de concepts.

11. CONCLUSIONS

Nous avons expérimenté les deux phases de détection de buzz pour un document : l'extraction du concept dominant (titre et tags) et le degré de "buzzabilité". Nous allons alors conclure sur chaque point.



Figure 8. Recupération de la vidéo et des tags à partir de Youtube




Figure 9. Méthodes d'intersection et d'union des concepts pour déterminer les tags à partir de la retranscription de la vidéo.




Figure 10. *F_score pour chaque méthodes d'extraction de tags à partir de vidéo de youtube sur l'actualité en français.*

11.1. Conclusion sur le titrage automatique

Nous avons utilisé LDA pour extraire un ensemble de concepts pour chaque corpus. Puis nous avons projeté un document dans cet espace de concepts pour en extraire les concepts les plus proches. Nous avons déterminé le concept dominant du document par la méthode intersection en tenant compte des "chunks" ou pas. Nous avons extrait du document les n^{28} mots ayant le *tf.idf* le plus élevés. Nous avons ensuite évalué les titres composés de mots issus des deux méthodes avec et sans prise en compte des "chunks" du *topic*. Nous constatons que les résultats sont proches quel que soit le corpus utilisé. Ceci nous porte à croire que le titre contient suffisamment d'information pour contenir les différents thèmes abordés dans le corps du texte. Nous remarquons que le titre trouvé est le plus proche du titre original lorsque l'on constitue le titre trouvé de mots issus du *tf.idf* et de l'intersection. Ainsi la prise en compte des concepts véhiculés dans le document nous permet d'extraire des informations qui n'apparaissent pas dans ce même document.

11.2. Conclusion sur l'extaction de tags

L'extraction de tags présente plus de difficultés car elle est réalisée depuis le texte en sortie de l'ASR et non plus d'un document journalistique proprement rédigé. Pour ces raisons nous obtenons des documents souvent mal écrits avec des mots inappropriés comme "euh", ... En plus d'améliorer les résultats quantitatifs, l'intérêt majeur de la méthode proposée est lié à la dissociation d'une méthode statique, lourde à estimer, et une représentation dynamique obtenue par l'intersection des classes statiques qui représentent le concept dominant du document. L'extraction de tags depuis des vidéos

28. n = nombre de mots constituant le titre original de l'AFP

issues de youtube n'a pas été étudié jusqu'à présent. Cette tâche est différente de l'extraction de mots clés due à la différence entre un document écrit par un homme et celui issu de la retranscription de la machine.

12. PERSPECTIVE :MEDIAEVAL

Médiévale²⁹ est une initiative d'analyse comparative consacrée à l'évaluation de nouveaux algorithmes pour l'accès et la récupération de documents multimédia. Il attire des participants intéressés par des approches multimodales traitant de flux multimédia. Par exemple, la reconnaissance vocale, l'analyse de contenu multimédia, des informations (tags, tweets) fournie par l'utilisateur Médiéval a été créé en 2008 comme VideoCLEF, une piste de CLEF, et en 2010 est devenu une initiative d'analyse comparative indépendante.

La tâche dans laquelle j'ai été inscrit est la "détection d'événements sociaux" à partir de documents vidéos, audios, images et quelques tags. Un premier traitement est au préalable réalisé par une structure composée de Mr San Juan et Mr Jourlin. Lors de ce traitement seront alors extraits à partir d'une requête et d'un corpus d'évaluation, un ensemble de documents répondant correspondant à la requête. Ma contribution sera alors de classer les documents grâce à leurs projections dans l'espace sémantique.

13. Bibliographie

- [ADH 56] ADHIKARI B., JOSHI D., Distance discrimination et résumé exhaustif , *Publ. Inst. Statist. Univ. Paris*, vol. 5, 1956, p. 57–74.
- [BAC 10] BACCIANELLA S., ESULI A., SEBASTIANI F., SentiWordNet 3.0 : An enhanced lexical resource for sentiment analysis and opinion mining , *Seventh conference on International Language Resources and Evaluation, Malta. Retrieved May*, vol. 25, 2010, page 2010.
- [BAN 00] BANKO M., MITTAL V., WITBROCK M., Headline generation based on statistical translation , *Proceedings of the 38th Annual Meeting on Association for Computational Linguistics*, Association for Computational Linguistics, 2000, p. 318–325.
- [BER 95] BERRY M., DUMAIS S., O'BRIEN G., Using linear algebra for intelligent information retrieval , *SIAM review*, vol. 37, n° 4, 1995, p. 573–595, JSTOR.
- [BLE 03] BLEI D., NG A., JORDAN M., Latent dirichlet allocation , *The Journal of Machine Learning Research*, vol. 3, 2003, p. 993–1022, JMLR. org.
- [BOZ 09] BOZZI L., SUIGNARD P., WAAST-RICHARD C., Segmentation et classification non supervisée de conversations téléphoniques automatiquement retranscrites , *Actes de la conférence TALN*, vol. 9, 2009.
- [BRA 99] BRADLEY M., LANG P., Affective norms for English words (ANEW) : Instruction manual and affective ratings , *University of Florida : The Center for Research in Psychophysiology*, , 1999.

29. <http://www.multimediaeval.org/mediaeval2011/>

- [BRI 98] BRIN S., PAGE L., The anatomy of a large-scale hypertextual Web search engine* 1, *Computer networks and ISDN systems*, vol. 30, n° 1-7, 1998, p. 107–117, Elsevier.
- [CHA 07] CHAUMARTIN F., WordNet et son écosystème : un ensemble de ressources linguistiques de large couverture, *Tables des matières*, , 2007, page 59, Citeseer.
- [CHE 02] CHEN K., MA W., Unknown word extraction for Chinese documents, *Proceedings of the 19th international conference on Computational linguistics-Volume 1*, Association for Computational Linguistics, 2002, p. 1–7.
- [CHI 99] CHIEN L., PAT-Tree-Based Adaptive Keyphrase Extraction for Intelligent Chinese Information Retrieval., *Information processing & management*, vol. 35, n° 4, 1999, p. 501–21.
- [CHO 03] CHOI E., LEE C., Feature extraction based on the Bhattacharyya distance, *Pattern Recognition*, vol. 36, n° 8, 2003, p. 1703–1709, Elsevier.
- [D'A 04] D'AVANZO E., MAGNINI B., VALLIN A., Keyphrase extraction for summarization purposes : The LAKE system at DUC-2004, *Proceedings of the 2004 Document Understanding Conference*, 2004.
- [DAN 10] DANESI C., CLAVEL C., Impact of spontaneous speech features on business concept detection : a study of call-centre data., *Proceedings of the 2010 international workshop on Searching spontaneous conversational speech*, ACM, 2010, p. 11–14.
- [DEE 90] DEERWESTER S., DUMAIS S., FURNAS G., LANDAUER T., HARSHMAN R., Indexing by latent semantic analysis, *Journal of the American society for information science*, vol. 41, n° 6, 1990, p. 391–407, Citeseer.
- [DEN] DENECKE K., Are SentiWordNet scores suited for multi-domain sentiment classification?, *Digital Information Management, 2009. ICDIM 2009. Fourth International Conference on*, IEEE, p. 1–6.
- [DEN 08] DENECKE K., Using SentiWordNet for multilingual sentiment analysis, *Data Engineering Workshop, 2008. ICDEW 2008. IEEE 24th International Conference on*, Ieee, 2008, p. 507–512.
- [DIJ 71] DIJKSTRA E., EINDHOVEN T. H., A short introduction to the art of programming, , 1971, Technische Hogeschool Eindhoven.
- [DRE 02] DREYFUS G., MARTINEZ J., SAMUELIDES M., GORDON M., BADRAN F., THIRIA S., HÉRAULT L., Réseaux de neurones, *Méthodologie et applications*, Eyrolles, , 2002.
- [FRO 07] FROISSAR P., Buzz, bouffées d'audience et rumeur sur Internet, , 2007, INA, Bry-sur-Marne (FRA).
- [GAR 08] GARNIER-RIZET M., ADDA G., CAILLIAU F., GAUVAIN J., GUILLEMIN-LANNE S., LAMEL L., VANNI S., WAAST-RICHARD C., CallSurf-Automatic transcription, indexing and structuration of call center conversational speech for knowledge extraction and query by content, *Proceedings of LREC*, 2008.
- [GEL 02] GELBUKH A., *Computational linguistics and intelligent text processing*, Springer, 2002.
- [GEN 08] GENG L., WANG H., WANG X., KORBA L., Adapting LDA Model to Discover Author-Topic Relations for Email Analysis, *Data Warehousing and Knowledge Discovery*, , 2008, p. 337–346, Springer.

- [HOF 99a] HOFMANN T., Probabilistic latent semantic analysis , *Proc. of Uncertainty in Artificial Intelligence, UAI'99*, Citeseer, 1999, page 21.
- [HOF 99b] HOFMANN T., Probabilistic latent semantic indexing , *Proceedings of the 22nd annual international ACM SIGIR conference on Research and development in information retrieval*, ACM, 1999, p. 50–57.
- [HOT 03] HOTH O A., STAAB S., STUMME G., Wordnet improves text document clustering , *Proc. of the SIGIR 2003 Semantic Web Workshop*, Citeseer, 2003, p. 541–544.
- [KEN 00] KENNEDY P., HAUPTMANN A., Automatic title generation for EM , *Proceedings of the fifth ACM conference on Digital libraries*, ACM, 2000, p. 230–231.
- [KLE 99] KLEINBERG J., Authoritative sources in a hyperlinked environment , *Journal of the ACM (JACM)*, vol. 46, n° 5, 1999, p. 604–632, ACM.
- [Kub 01] KUBOTA ANDO R., LEE L., Iterative Residual Rescaling : An Analysis and Generalization of LSI , , 2001.
- [KUL 51] KULLBACK S., LEIBLER R., On information and sufficiency , *The Annals of Mathematical Statistics*, vol. 22, n° 1, 1951, p. 79–86, JSTOR.
- [KUM 05] KUMAR P., KUMAR K., RAO T., REDDY P., An improved approach to extract document summaries based on popularity , *Databases in Networked Information Systems*, , 2005, p. 310–318, Springer.
- [MAR 04] MARCUS A., SERGEYEV A., RAJLICH V., MALETIC J., An information retrieval approach to concept location in source code , *Reverse Engineering, 2004. Proceedings. 11th Working Conference on*, IEEE, 2004, p. 214–223.
- [MCC 02] MCCALLUM A., Mallet : A machine learning for language toolkit , , 2002.
- [NAD 93] NADAL J., Réseaux de Neurones , *De la physique à la psychologie*, Armand Colin, , 1993.
- [PAR 10] PAROUBEK A., Construction d'un lexique affectif pour le français à partir de Twitter , , 2010.
- [RIG 06] RIGOUSTE L., CAPPÉ O., YVON F., Quelques observations sur le modele LDA , *Actes des IXe JADT*, , 2006, p. 819–830.
- [ROD 00] RODRÍGUEZ M., HIDALGO J., AGUDO B., Using WordNet to complement training information in text categorization , *Recent advances in natural language processing II : selected papers from RANLP'97*, vol. 189, 2000, page 353, John Benjamins Publishing Company.
- [SAG 10] SAGGION H., FUNK A., Interpreting SentiWordNet for Opinion Classification , *Proceedings of the Seventh conference on International Language Resources and Evaluation LREC10*, n° i, European Language Resources Association (ELRA), 2010, p. 1129–1133.
- [SAL 88] SALTON G., BUCKLEY C., Term-weighting approaches in automatic text retrieval* 1 , *Information processing & management*, vol. 24, n° 5, 1988, p. 513–523, Elsevier.
- [SAL 89] SALTON G., Automatic text processing : the transformation , *Analysis and Retrieval of Information by Computer*, , 1989, S. l.] : Addison-Wesley Publishing Co.
- [SCH 11] SCHUR J., Bemerkungen zur Theorie der beschränkten Bilinearformen mit unendlich vielen Veränderlichen. , *Journal für die reine und angewandte Mathematik (Crelle's Journal)*, vol. 1911, n° 140, 1911, p. 1–28, Walter de Gruyter, Berlin/New York Berlin, New York.

- [SIM 10] SIM S., ONG S., Parameter Estimation for Discrete Distributions by Generalized Hellinger-Type Divergence Based on Probability Generating Function , *Communications in Statistics-Simulation and Computation*, vol. 39, n° 2, 2010, p. 305–314, Taylor & Francis.
- [TAN 06] TAN P., STEINBACH M., KUMAR V. et al., *Introduction to data mining*, Pearson Addison Wesley Boston, 2006.
- [TOD 10] TODERICI G., ARADHYE H., PASCA M., SBAIZ L., YAGNIK J., Finding meaning on youtube : tag recommendation and category discovery , , 2010, IEEE.
- [WAN 10] WANG J., Unsupervised multilingual concept discovery from daily online news extracts , *Intelligence and Security Informatics (ISI)*, 2010 IEEE International Conference on, IEEE, 2010, p. 132–134.
- [WIT 99] WITBROCK M., MITTAL V., Ultra-summarization (poster abstract) : a statistical approach to generating highly condensed non-extractive summaries , *Proceedings of the 22nd annual international ACM SIGIR conference on Research and development in information retrieval*, ACM, 1999, p. 315–316.
- [YAM 08] YAMAMOTO D., MASUDA T., OHIRA S., NAGAO K., Collaborative Video Scene Annotation Based on Tag Cloud , *Advances in Multimedia Information Processing-PCM 2008*, , 2008, p. 397–406, Springer.
- [ZHA 10] ZHANG W., YOSHIDA T., TANG X., A comparative study of TF*IDF, LSI and multi-words for text classification , *Expert Systems With Applications*, , 2010, Elsevier.